

OSINT Forensics

Forensic des Réseaux Sociaux & Vol d'Identité

Rapport de Projet

Présenté par :

Berkani Yasser

M1 Sécurité Informatique

Avril 2026

Résumé Exécutif

Ce rapport présente un système complet d'investigation OSINT (Open Source Intelligence) conçu pour relier des comptes de réseaux sociaux anonymes ou inconnus à des identités réelles. Le projet combine plusieurs techniques forensiques avancées incluant l'énumération de noms d'utilisateur sur plus de 444 plateformes, l'extraction de métadonnées EXIF des images, l'analyse historique via Wayback Machine, et la corrélation multi-sources pour établir un score de confiance d'identification.

L'application web développée utilise Python Flask comme backend et propose une interface utilisateur interactive en deux phases : découverte automatisée de comptes et analyse approfondie avec scoring forensique. Le système génère des rapports détaillés au format texte et JSON pour faciliter l'exploitation des résultats dans des contextes d'investigation réels.

1. Introduction

1.1 Contexte et Problématique

Dans le contexte actuel de cybersécurité, l'identification d'individus à partir de leurs activités en ligne constitue un enjeu majeur pour les enquêtes forensiques. Les acteurs malveillants utilisent fréquemment des pseudonymes et des comptes anonymes pour masquer leur identité réelle, rendant leur traçabilité complexe. Ce projet répond à cette problématique en développant un outil automatisé d'investigation OSINT capable de corréler des informations dispersées sur de multiples plateformes sociales.

1.2 Objectifs du Projet

Les objectifs principaux sont :

- Automatiser la recherche d'identités numériques sur 444+ plateformes sociales
- Extraire et analyser les métadonnées EXIF des images (GPS, timestamps, appareil photo)
- Exploiter les archives historiques via Wayback Machine pour tracer l'évolution des comptes
- Corréler les preuves collectées et calculer un score de confiance d'identification
- Générer des rapports forensiques exploitables au format texte et JSON

2. Architecture Technique

2.1 Stack Technologique

Le système repose sur une architecture web modulaire développée en Python avec les composants suivants :

- Backend : Flask (serveur web Python avec support Server-Sent Events)
- Frontend : HTML/CSS/JavaScript (interface utilisateur interactive mono-page)
- Bibliothèque Sherlock : Intégration pour la recherche multi-plateforme
- Pillow : Extraction de métadonnées EXIF des images
- Requests : Communication avec Wayback Machine CDX API et scraping de profils

2.2 Structure Modulaire

Le projet est organisé en modules indépendants pour faciliter la maintenance et l'évolutivité :

Module	Fonction
app.py	Serveur Flask principal, gestion des routes HTTP et SSE
sherlock_module.py	Phase 1 - Génération de variations de usernames et recherche sur 444 sites
metadata_module.py	Phase 2 - Extraction EXIF, requêtes Wayback Machine, analyse de profils
correlation_engine.py	Moteur de corrélation multi-sources et calcul du score de confiance
report_generator.py	Génération de rapports forensiques au format TXT et JSON

3. Méthodologie d'Investigation

3.1 Phase 1 : Découverte de Comptes (Sherlock)

La première phase automatise la découverte de comptes associés à une identité cible. À partir d'un nom complet (ex : 'John Doe'), le système génère automatiquement des variations de noms d'utilisateur selon plusieurs patterns :

- Concaténation simple : johndoe
- Avec underscore : john_doe
- Avec point : john.doe
- Initiales + nom : jdoe
- Inversions : doejohn, doe_john
- Troncatures : johnd, doe_joh

Pour chaque variation, le système interroge 444 plateformes sociales en parallèle (15 threads). La validation s'effectue selon trois stratégies en fonction du type d'erreur défini par la plateforme :

- status_code : Le compte existe si l'URL retourne 200 mais une URL invalide ne retourne pas 200
- message : Le compte existe si la page ne contient pas le message d'erreur défini
- response_url : Le compte existe si l'URL finale après redirections ne correspond pas à l'URL d'erreur

Chaque compte trouvé est immédiatement diffusé vers le navigateur via Server-Sent Events (SSE), permettant à l'utilisateur de voir les résultats apparaître en temps réel sans attendre la fin de la recherche.

3.2 Phase 2 : Analyse Approfondie

La deuxième phase permet à l'utilisateur de sélectionner les comptes pertinents découverts en Phase 1 pour une analyse forensique détaillée. Cette phase combine trois sources de données indépendantes :

3.2.1 Analyse Wayback Machine

Le système interroge l'API CDX de Wayback Machine pour chaque URL de compte sélectionné. Cette requête retourne l'historique complet des captures archivées :

- Date de première apparition (first_seen) : indique quand le compte a été créé
- Date de dernière capture (last_seen) : indique l'activité récente
- Nombre total de snapshots archivés
- Liste des années d'activité détectées
- Liens vers les 10 premiers snapshots pour consultation manuelle

3.2.2 Extraction de Métadonnées EXIF

Si l'utilisateur télécharge une image de profil, le système extrait automatiquement les métadonnées EXIF qui peuvent contenir des informations critiques :

- Coordonnées GPS (GPSInfo) : Converties en latitude/longitude décimales avec génération automatique d'un lien Google Maps pour géolocalisation
- Timestamp de capture (DateTimeOriginal) : Date et heure exactes de la prise de photo
- Appareil photo (Make/Model) : Marque et modèle de l'appareil utilisé
- Logiciel (Software) : Révèle si l'image a été éditée et avec quel logiciel

3.2.3 Analyse de Pages de Profil

Le système télécharge et analyse le HTML de chaque page de profil pour extraire :

- Attribut lang= de la balise <html> : Indique la langue du profil
- Meta tag og:image : URL de la photo de profil, téléchargée et hashée en MD5
- Meta tag og:description : Tentative d'extraction de localisation textuelle
- Balise <title> : Titre de la page de profil

Le hash MD5 de l'image de profil constitue le signal le plus fort : si deux comptes sur des plateformes différentes partagent le même hash, il s'agit très probablement de la même personne.

4. Moteur de Corrélation et Scoring

4.1 Algorithme de Corrélation

Le moteur de corrélation agrège toutes les preuves collectées et calcule un score de confiance sur une échelle de 0 à 100. Chaque signal détecté contribue au score selon une pondération définie :

Signal Forensique	Points	Détection
Hash d'image de profil identique	+35	MD5 match sur 2+ comptes
Coordonnées GPS EXIF	+25	GPS trouvé dans image
Même année de création de compte	+15	first_seen Wayback match
Chevauchement timeline d'activité	+15	Années actives communes
Même langue HTML sur profils	+10	Attribut lang= identique
Timestamp EXIF de capture	+10	DateTime trouvé
Historique Wayback par compte	+5 chacun	Max +15 pts
Bonus nombre de comptes	+5 chacun	Max +20 pts

4.2 Classification par Niveau de Risque

Le score final est traduit en un niveau de risque d'identification selon les seuils suivants :

- MINIMAL (0-25 points) : Preuves insuffisantes, identification très incertaine
- LOW (26-50 points) : Quelques indices concordants, nécessite vérifications supplémentaires
- MEDIUM (51-75 points) : Corrélations significatives, identification probable
- HIGH (76-100 points) : Preuves multiples convergentes, forte confiance d'identification

5. Cas d'Usage Pratique

5.1 Scénario : Identification d'un Suspect

Contexte :

Un username 'shadow_x' publie du contenu suspect en ligne. L'objectif est d'identifier l'individu réel derrière ce pseudonyme.

Étape 1 - Recherche initiale :

Saisie de 'shadow x' dans l'interface. Le système génère les variations : shadowx, shadow_x, shadow.x, sx, shadowx, xshadow, x_shadow

Résultats Sherlock découvre :

- GitHub : https://github.com/shadow_x
- Reddit : https://reddit.com/user/shadow_x
- DeviantArt : https://deviantart.com/shadow_x

Étape 2 - Sélection et analyse approfondie :

Les trois comptes sont sélectionnés. Une image de profil trouvée sur GitHub est téléchargée pour analyse EXIF.

Étape 3 - Preuves collectées :

- Wayback Machine : GitHub archivé pour la première fois en 2019, Reddit également en 2019
- **Signal détecté : Même année de création → +15 points**
- Timeline d'activité : Les deux comptes montrent une activité en 2019, 2020, 2021
- **Signal détecté : Chevauchement temporel → +15 points**
- Hash MD5 des images de profil : og:image sur GitHub et Reddit produisent le même hash
- **Signal détecté : Photo de profil identique → +35 points**
- EXIF GPS : L'image téléchargée contient des coordonnées GPS : 48.8566, 2.3522 (Paris, France)
- **Signal détecté : Géolocalisation → +25 points**
- Langue des profils : GitHub et Reddit ont tous deux lang='fr' dans leur balise HTML
- **Signal détecté : Même langue → +10 points**

Résultat final :

Score de confiance : 85/100 — Niveau de risque : HIGH

Conclusion : Les preuves convergent vers une personne francophone localisée à Paris, ayant créé plusieurs comptes en 2019 avec la même photo de profil. L'identification est hautement probable et justifie une investigation approfondie supplémentaire.

6. Limitations et Perspectives


6.1 Limitations Techniques

- Usernames aléatoires : Si le compte cible utilise un pseudonyme totalement aléatoire (ex : xk7r29z) sans lien avec l'identité réelle, Sherlock ne pourra pas le découvrir
- Scraping des réseaux modernes : Twitter/Instagram/TikTok bloquent activement les scrapers, rendant l'extraction de og:image et lang= difficile sur ces plateformes
- Suppression EXIF : La plupart des plateformes sociales (Facebook, Twitter) suppriment automatiquement les métadonnées EXIF des images téléchargées. L'analyse EXIF fonctionne principalement sur des images provenant de sources moins traitées (GitHub, sites personnels, forums)
- Faux positifs : Des homonymes ou des personnes utilisant des patterns de username similaires peuvent générer des faux positifs nécessitant validation manuelle


6.2 Améliorations Futures

- Intégration d'API officielles : Utiliser les API Twitter, LinkedIn, Facebook (lorsque disponibles) pour des données plus fiables que le scraping
- Analyse comportementale : Intégrer l'analyse de style d'écriture, patterns temporels de publication, et intérêts communs pour renforcer la corrélation
- Machine Learning : Implémenter un modèle de scoring adaptatif qui apprend des cas validés pour améliorer la précision de la pondération
- Reconnaissance faciale : Ajouter la comparaison de photos de profil par analyse d'images pour renforcer la détection au-delà du simple hash MD5
- Export visualisé : Générer des graphes de relations entre comptes et des timelines visuelles pour faciliter l'analyse forensique

7. Diagramme de cas d'utilisation



8. Diagramme d'activité



9. Conclusion

Ce projet démontre la puissance des techniques OSINT appliquées à l'investigation forensique des identités numériques. En combinant énumération automatisée sur 444 plateformes, extraction de métadonnées EXIF, analyse d'archives Wayback Machine et corrélation multi-sources, le système construit une chaîne de preuves permettant d'établir des liens entre comptes anonymes et identités réelles.

L'architecture modulaire et l'interface web interactive facilitent le processus d'investigation en automatisant les tâches répétitives et en présentant les résultats de manière structurée. Le moteur de corrélation, avec son système de scoring pondéré, offre une évaluation objective de la confiance d'identification basée sur des signaux forensiques concrets.

Bien que certaines limitations techniques subsistent (notamment sur les plateformes modernes avec protections anti-scraping), l'outil s'avère efficace dans de nombreux scénarios réels d'investigation. Les perspectives d'évolution incluent l'intégration d'analyses comportementales et de machine learning pour améliorer encore la précision du système.

Ce travail illustre comment l'automatisation intelligente peut démultiplier les capacités d'investigation en cybersécurité, tout en soulignant l'importance du respect de la vie privée et de l'éthique dans l'utilisation de telles techniques.